

TP Chapitre 2 : Pipeline Données dlt, dbt & Dagster

Étudiant: SIFEDDINE LEGNIOUI

1. Objectif & Schéma

Pipeline : **Ingestion** (dlt) → **Validation** → **Transformation** (dbt) → **Tests** → **Orchestration** (Dagster)

1. Captures d'Écran

```
PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUI_SIFEDDINE\tp_chapitre2_pipeline> .venv\Scripts\Activate.ps1  
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUI_SIFEDDINE\tp_chapitre2_pipeline> python pipeline/ingest.py  
Ingestion terminée : ventes_raw créée dans DuckDB  
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUI_SIFEDDINE\tp_chapitre2_pipeline> |
```

Figure 1 – 1. Ingestion : python pipeline/ingest.py

```
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUI_SIFEDDINE\tp_chapitre2_pipeline> python pipeline/validate.py  
Validation réussie : schéma et qualité minimale OK  
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUI_SIFEDDINE\tp_chapitre2_pipeline> |
```

Figure 2 – 2. Validation : python pipeline/validate.py

```
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIQUI_SIFEDDINE\tp_chapitre2_pipeline\dbt_pipeline> dbt run --profiles-dir .
23:04:39 Running with dbt=1.11.11
23:04:40 Registered adapter: duckdb=1.10.1
23:04:40 Unable to do partial parsing because saved manifest not found. Starting full parse.
23:04:55 Found 2 models, 3 data tests, 485 macros
23:04:55
23:04:55 Concurrency: 1 threads (target='dev')
23:04:55
23:05:09 1 of 2 START sql table model main.ventes_clean ..... [RUN]
23:05:09 1 of 2 OK created sql table model main.ventes_clean ..... [OK in 0.16s]
23:05:09 2 of 2 START sql table model main.ventes_resume ..... [RUN]
23:05:09 2 of 2 OK created sql table model main.ventes_resume ..... [OK in 0.06s]
23:05:09
23:05:09 Finished running 2 table models in 0 hours 0 minutes and 13.34 seconds (13.34s).
23:05:09
23:05:09 Completed successfully
23:05:09
23:05:09 Done. PASS=2 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=2
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIQUI_SIFEDDINE\tp_chapitre2_pipeline\dbt_pipeline> |
```

Figure 3 – 3. dbt run : dbt run --profiles-dir .

```
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIQUI_SIFEDDINE\tp_chapitre2_pipeline\dbt_pipeline> dbt test --profiles-dir .
23:06:25 Running with dbt=1.11.11
23:06:25 Registered adapter: duckdb=1.10.1
23:06:26 Found 2 models, 3 data tests, 485 macros
23:06:26
23:06:26 Concurrency: 1 threads (target='dev')
23:06:26
23:06:26 1 of 3 START test not_null_ventes_clean_produit ..... [RUN]
23:06:26 1 of 3 PASS not_null_ventes_clean_produit ..... [PASS in 0.07s]
23:06:26 2 of 3 START test not_null_ventes_clean_quantite ..... [RUN]
23:06:26 2 of 3 PASS not_null_ventes_clean_quantite ..... [PASS in 0.02s]
23:06:26 3 of 3 START test not_null_ventes_resume_categorie ..... [RUN]
23:06:26 3 of 3 PASS not_null_ventes_resume_categorie ..... [PASS in 0.02s]
23:06:26
23:06:26 Finished running 3 data tests in 0 hours 0 minutes and 0.32 seconds (0.32s).
23:06:26
23:06:26 Completed successfully
23:06:26
23:06:26 Done. PASS=3 WARN=0 ERROR=0 SKIP=0 NO-OP=0 TOTAL=3
```

Figure 4 – 4. dbt test : dbt test --profiles-dir .




Figure 5 – 5. Dagster graphe




Figure 6 – 6. Dagster exécution

1. Historique Git

```
(.venv) PS C:\Users\crime\OneDrive\Desktop\TP2_LEGNIOUTI_SIFEDDINE\tp_chapitre2_pipeline> git log --oneline
b69a849 (HEAD -> main) Correction des paramètres de l'orchestrateur Dagster
e7ff5d3 Ajout d'une CI simple
3ebcfb9 Ajout de l'orchestration Dagster
2c56613 Ajout des tests simples dbt
9f881ec Ajout des modèles dbt
3dd62a8 Ajout de l'étape de validation minimale
44d016b Ajout de l'étape d'ingestion
23e8239 Initialisation du projet pipeline
```

1. Structure & Commandes

Projet : data/ventes.csv → pipeline/{ingest,validate,orchestrate}.py → dbt_pipeline/models/{ve
→ ventes.duckdb

1. Livrables & Réponses

Dossier complet | 7 captures d'écran | Historique Git | Schéma pipeline | DuckDB | CI/CD

Q : Qu'est-ce que dlt ? Ingestion automatique de données avec gestion du schéma.

Q : Pourquoi dbt ? Transformation SQL reproductible avec tests et traçabilité.

Q : Rôle de Dagster ? Orchestration et monitoring du pipeline.

Q : Pourquoi Git/CI-CD ? Traçabilité du code et tests automatisés.

Q : Tests ? not_null sur produit, quantite, categorie.

Q : Reproduire ? Installer → ingest → validate → dbt run/test → dagster dev